



MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL
MCDI501: Estadística Computacional para la Toma de Decisiones

Evaluación Sumativa 1

Análisis Exploratorio e Inferencial

Informe técnico grupal · 20 %

Título del proyecto:	Modelamiento Estadístico e Inferencia para la Detección Temprana de la Enfermedad Renal Crónica en Pacientes de la India
Integrantes:	Treici D. Medina Lizama
Dataset:	Dataset 2: Chronic Kidney Disease
Docente:	JEAN PAUL MAIDANA GONZALEZ
Fecha:	28/06/2026
Repositorio GitHub:	https://github.com/treicimedina/Enfermedad-Renal

Información de la evaluación	
Fase del proyecto:	Fase 2: Búsqueda y recopilación de información
Modalidad:	Grupal (3-4 integrantes)
Ponderación:	20 % de la nota final
Entregables:	Informe PDF (máx. 8 págs., sin anexos) · Notebook .ipynb · Repositorio GitHub
Resultado de aprendizaje:	RA1: aplicar probabilidad e inferencia estadística en problemas de decisión bajo incertidumbre.
Indicadores:	ID1.2, ID1.3, ID1.4
Recuerden:	los resultados de esta sumativa serán la entrada de S2 y S3.

Índice

Índice	2
Preparación y carga de datos	3
Análisis exploratorio de datos	3
Estimación de parámetros	3
Pruebas de hipótesis	4
Informe de avance del proyecto	5
Notebook y repositorio GitHub	6
Bibliografía (APA 7).....	6

Preparación y carga de datos

Dimensión real de los datos filtrados:

El archivo .arff original se cargó omitiendo 3 líneas corruptas mediante `on_bad_lines='skip'`. Las dimensiones de trabajo finales son de 397 filas y 25 columnas.

Distribución de la variable objetivo (class):

- Pacientes con Enfermedad Renal Crónica (ckd): 248 pacientes (62.47%).
- Pacientes Sanos (notckd): 149 pacientes (37.53%).
-

Corrección de Tipos de Datos e Incongruencias:

- Las columnas pcv (hematocrito), wbcc (recuento de glóbulos blancos) y rbcc (recuento de glóbulos rojos) contenían caracteres mal formateados, por lo que se hizo su conversión a tipo numérico (`pd.to_numeric`).
- Se eliminaron espacios en blanco y tabulaciones ocultas (`\t`, `\n`) en todas las columnas cualitativas usando funciones de limpieza de cadenas (`.str.strip()`).

Análisis exploratorio de datos

<i>Variable Analizada</i>	<i>Muestra Válida (n)</i>	<i>Media Muestral ($\bar{x}$)</i>	<i>Mediana ($x_{\sim}$)</i>	<i>Desviación Estándar (s)</i>	<i>Mínimo</i>	<i>Máximo</i>
<i>Edad (age)</i>	388	51.456	54.5	17.134	2.0	90.0
<i>Presión Arterial (bp)</i>	385	76.468	80.0	13.712	50.0	180.0
<i>Hemoglobina (hemo)</i>	345	12.521	12.6	2.918	3.1	17.8
<i>Glucosa en Sangre (bgr)</i>	353	147.864	121.0	79.290	22.0	490.0
<i>Urea en Sangre (bu)</i>	378	57.609	42.0	50.651	1.5	391.0
<i>Creatinina Sérica (sc)</i>	380	3.088	1.3	5.761	0.4	76.0

Estimación de parámetros

Utilizando la distribución *t-Student* para manejar adecuadamente la pérdida de grados de libertad debida a los registros faltantes (datos nulos), los intervalos para la media poblacional de los signos vitales críticos son:

1. **Edad (age):**
 - $n = 388$
 - Estimación puntual: **51.456**
 - IC 95%: **[49.746, 53.166]**
2. **Presión Arterial (bp):**
 - $n = 385$
 - Estimación puntual: **76.468**
 - IC 95%: **[75.094, 77.842]**
3. **Hemoglobina (hemo):**
 - $n = 345$
 - Estimación puntual: **12.521**
 - IC 95%: **[12.212, 12.830]**

Pruebas de hipótesis

Prueba 1: Comparación de Medias de Hemoglobina entre Grupos (t-Student para muestras independientes)

- **Planteamiento:** Se evalúa si el nivel medio de hemoglobina difiere significativamente entre pacientes diagnosticados con ERC y pacientes sanos. No se asumen varianzas iguales (Corrección de Welch).
- **Resultados:**
 - Estadístico $t = -24.5765$
 - $p\text{-valor} = 8.6433 \times 10^{-77}$ (Extremadamente menor a $\alpha = 0.05$).
- **Conclusión Estadística:** Se rechaza la hipótesis nula (H_0). Existe evidencia estadística contundente de que los pacientes con Enfermedad Renal Crónica presentan niveles significativamente más bajos de hemoglobina (anemia asociada) en comparación con el grupo sano.

Prueba 2: Asociación de Hipertensión Arterial con ERC (Chi-Cuadrado de Independencia)

- **Planteamiento:** Se evalúa la dependencia entre sufrir de Hipertensión Arterial (htn) y el diagnóstico final (class).
- **Tabla de Contingencia Observada:**
 - Pacientes Sin Hipertensión (htn = no): **102** Crónicos / **147** Sanos.
 - Pacientes Con Hipertensión (htn = yes): **146** Crónicos / **0** Sanos.
- **Resultados:**
 - Estadístico $\chi^2 = 134.7678$
 - Grados de libertad (gl) = 1
 - $p\text{-valor} = 3.7112 \times 10^{-31}$ (Menor a $\alpha = 0.05$).
- **Conclusión Estadística:** Se rechaza la hipótesis nula de independencia. Existe una asociación estadística altamente significativa entre tener hipertensión y padecer ERC. De hecho, en esta muestra, el 100% de los pacientes hipertensos presentaba la enfermedad.

Informe de avance del proyecto

Introducción al Problema

La Enfermedad Renal Crónica (ERC) es una crisis de salud pública global caracterizada por la pérdida progresiva e irreversible de la función renal, cuya naturaleza asintomática en etapas tempranas retrasa el diagnóstico oportuno y deriva en costosas terapias de sustitución y alta morbilidad cardiovascular. En entornos en vías de desarrollo, las barreras socioeconómicas y la falta de infraestructura para tamizajes universales exacerban esta problemática. Por consiguiente, existe una necesidad crítica de identificar biomarcadores clínicos secundarios, accesibles y de bajo costo, que actúen como alertas predictivas analizadas a partir de datos como los del Hospital Apollo (India), cuya muestra depurada para este estudio consta de 397 pacientes: 248 crónicos (62.47%) y 149 sanos (37.53%), evaluados a través de 25 atributos clínicos.

Descripción de Métodos Aplicados

El flujo metodológico se estructuró en cuatro fases computacionales y estadísticas automatizadas en Python. Primero, se realizó el saneamiento de datos mediante la omisión de líneas corruptas, la conversión de nulos (NaN), la eliminación de espacios ocultos y el forzado a tipo numérico de variables mal formateadas (pcv, wbcc, rbcc). Segundo, el Análisis Exploratorio de Datos (AED) aplicó estadística descriptiva, gráficos de densidad y cajas para identificar la separación de las distribuciones. Tercero, se realizó la parametrización construyendo intervalos de confianza al 95% basados en la distribución t-Student para mitigar la pérdida de grados de libertad por registros faltantes. Finalmente, se ejecutaron contrastes de hipótesis mediante la prueba t de Welch para evaluar medias de hemoglobina y la prueba de Chi-cuadrado (χ^2) de Pearson para cuantificar la dependencia entre hipertensión y ERC.

Resumen de Resultados

La auditoría de calidad descartó duplicados, pero detectó una omisión crítica de datos (25% al 32%) en el conteo celular avanzado. Los estadísticos basales arrojaron una edad media de 51 años ($s = 17.13$) y una presión arterial promedio de 76.46 mm/Hg ($s = 13.71$). La hemoglobina global promedió 12.52 g/dl ($s = 2.91$), registrando un mínimo crítico de 3.1 g/dl que evidencia anemia severa. Por su parte, la urea en sangre y la creatinina sérica demostraron una marcada asimetría positiva con medianas estables en 42.0 mg/dl y 1.3 mg/dl respectivamente, pero con máximos extremos de hasta 391.0 mg/dl y 76.0 mg/dl que confirman la presencia de pacientes con una retención crítica de toxinas por daño renal.

Interpretaciones Preliminares

Las estimaciones poblacionales al 95% de confianza fijaron los intervalos de la media para la edad en [49, 53] años, la presión arterial en [75.09, 77.84] mm/Hg y la hemoglobina en [12.21, 12.83] g/dl, evidenciando un sesgo de selección institucional al provenir de centros privados. Los contrastes de hipótesis resultaron altamente significativos: la prueba t de Welch ($t = -24.57$, $p = 8.64 \times 10^{-77}$) confirmó que los pacientes con ERC tienen niveles de hemoglobina drásticamente menores debido a la caída en la síntesis de eritropoyetina, validando al hemograma como un indicador de bajo costo. Asimismo, la prueba de Chi-cuadrado ($\chi^2 = 134.76$, $p = 3.71 \times 10^{-31}$) demostró una estricta dependencia epidemiológica entre la hipertensión y la ERC; en esta muestra el 100% de los hipertensos presentó la enfermedad.

Próximos Pasos del Proyecto

Para la solución predictiva, en acciones que se enfocarán en la ciencia de datos y el modelado computacional. Se implementará una imputación avanzada mediante KNN Imputer o MICE para estimar los registros faltantes (NaN) sin sesgar las distribuciones, seguida de una codificación de variables cualitativas (*Label Encoding*) y una estandarización de variables continuas (*Z-score scaling*) para asegurar la convergencia de los optimizadores. Posteriormente, se entrenarán clasificadores de aprendizaje supervisado como Regresión Logística, Random Forest y SVM bajo un esquema de Validación Cruzada Estratificada de 10 pliegues (K=10). La optimización de hiperparámetros priorizará estrictamente la maximización de la Sensibilidad (Recall) y el área ROC-AUC, con el objetivo clínico obligatorio de reducir a cero los falsos negativos y garantizar la detección temprana de la patología.

Notebook y repositorio GitHub

El desarrollo analítico, la limpieza de datos y las pruebas presentadas en este informe se encuentran en el siguiente repositorio:

Repositorio Oficial en GitHub: <https://github.com/treicimedina/Enfermedad-Renal>

Bibliografía (APA 7)

India, C. D. (2015). *Early stage of Indians Chronic Kidney Disease (CKD)* [Dataset]. Repositorio de Aprendizaje Automático de Weka. UCI Machine Learning Repository.

SciPy Core Team. (2023). *Statistical methods and inference validation tools* (SciPy v1.11) [Software]. SciPy Documentation Series. <https://docs.scipy.org/doc/scipy/reference/stats.html>

Webster, A. C., Nagler, E. V., Morton, R. L., y Masson, P. (2017). Chronic kidney disease. *The Lancet*, 389(10075), 1238–1252. [https://doi.org/10.1016/S0140-6736\(16\)32064-5](https://doi.org/10.1016/S0140-6736(16)32064-5)