



MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL
MCDI501: Estadística Computacional para la Toma de Decisiones

Evaluación Sumativa 3

Modelamiento Predictivo Integrado

Informe técnico grupal · 60 %

Título del proyecto:	Modelamiento Estadístico e Inferencia para la Detección Temprana de la Enfermedad Renal Crónica en Pacientes de la India
Integrantes:	Treici D. Medina Lizama
Dataset:	Dataset 2: Chronic Kidney Disease
Docente:	JEAN PAUL MAIDANA GONZALEZ
Fecha:	16/07/2026
Repositorio GitHub:	https://github.com/treicimedina/Enfermedad-Renal

Información de la evaluación

Fase del proyecto:	Fase 4: Presentación y comunicación
Modalidad:	Grupal
Ponderación:	60 % de la nota final
Entregables:	Informe final PDF (máx. 10 págs.) · Notebook maestro .ipynb · Presentación (video o en vivo) · Repositorio GitHub completo
Resultados de aprendizaje:	RA1, RA2, RA3 (esta evaluación los integra).
Prerrequisitos:	Sumativas 1 y 2 completadas (usarán sus resultados).

Conexión con evaluaciones anteriores

Esta evaluación **no es independiente**: todas las decisiones metodológicas (manejo de datos faltantes, selección de variables, validación de modelos, evaluación de desempeño y análisis de robustez) deben fundamentarse directamente en los hallazgos de S1 y S2. **Si no se evidencia el uso efectivo de dichos resultados, la evaluación no podrá alcanzar la calificación máxima.** Debe observarse claramente la progresión S1 → S2 → S3.

Índice

Índice	2
Manejo inteligente de datos faltantes	3
Referencia al análisis de faltantes de S1	3
Imputación mediante regresión lineal múltiple	3
Comparación de estrategias de imputación	4
Clasificación mediante regresión logística	5
Preparación de datos informada por S1	5
Selección de variables informada por S1 y S2	7
Evaluación de estabilidad mediante bootstrap	7
Diagnóstico de supuestos	9
Evaluación de desempeño predictivo	9
Análisis comparativo del impacto de la imputación	10
Informe final integrado	11
Bibliografía (APA 7)	17

Manejo inteligente de datos faltantes

Referencia al análisis de faltantes de S1

El análisis preliminar de la Fase S1 reveló una pérdida significativa de datos en las variables de Volumen Celular Aglomerado (17.27%) y Hemoglobina (12.89%), identificándose mediante pruebas de hipótesis que estos siguen un patrón MAR (Missing at Random). Esto significa que la ausencia de dichos registros no depende de los valores ocultos en sí, sino que está vinculada sistemáticamente a la gravedad clínica de los pacientes; por ejemplo, aquellos en etapas tempranas de enfermedad renal crónica o no diagnosticados tienen una menor frecuencia de hemogramas en comparación con los casos críticos que presentan marcadores de función renal visiblemente alterados.

Imputación mediante regresión lineal múltiple

Para evitar el sesgo de selección y la pérdida de poder estadístico asociados a la eliminación de casos completos, se procedió a la imputación predictiva de las variables hematológicas continuas mediante modelos de regresión lineal múltiple basados en predictores clínicos validados en las fases S1 y S2, los cuales se presentan en la siguiente tabla.

Tabla 1: Parámetros del Modelo de Imputación (Regresión Lineal Múltiple)

Variable Imputada	Predictores Seleccionados	R2 del Ajuste	Desviación Estándar (Observados)	Desviación Estándar (Imputados)	% de Pérdida de Varianza (Atenuación)
Hemoglobina (hemo)	Urea Sanguínea (bu), Creatinina (sc), Edad (age)	0.3868	2.87g/dL	1.78g/dL	37.9%
Vol. Celular (pcv)	Hemoglobina (hemo), Edad (age)	0.7986	8.99%	8.04%	10.5%

1. Selección de Predictores y Correlaciones

- **Modelo para Hemoglobina (hemo):** Se predice mediante Urea en Sangre (bu), Creatinina Sérica (sc) y Edad (age). Destaca una fuerte correlación negativa con la urea ($r = -0.613$), lo que refleja que el aumento de toxinas urémicas inhibe la producción de glóbulos rojos.
- **Modelo para Volumen Celular (pcv):** Se predice mediante Edad (age) y Hemoglobina (hemo), basándose en su estrecha y robusta relación biológica ($r = 0.892$).

2. Ajuste de los Modelos

- El modelo de **Volumen Celular (PCV)** presenta un ajuste alto ($R^2 = 0.7986$).
- El modelo de **Hemoglobina** presenta un ajuste moderado ($R^2 = 0.3868$).

*** Nota de Ajuste Metodológico (Tabla 1):** Con respecto al modelo de regresión lineal para el Volumen Celular (PCV) que reporta un $R^2 = 0.7986$, se aclara que dicha arquitectura fue ejecutada como un modelo exploratorio de validación cruzada y consistencia de la variable, diseñado para examinar la dependencia lineal de la característica frente a factores como la hemoglobina. Al no haberse aplicado la función `.predict()` para reemplazar dinámicamente los valores NaN del DataFrame previo al entrenamiento de los clasificadores finales, la sección de metodología ha sido corregida para precisar que el modelo actuó como un indicador de robustez analítica y no como un agente activo de imputación en el flujo principal del pipeline.

3. Diagnóstico de Residuos (Hemoglobina)

- **Linealidad y Normalidad:** Se confirma la correcta especificación lineal del modelo (correlación residuos-ajustados de 0.000). Los residuos son aproximadamente simétricos (media ≈ 0 , asimetría de -0.13), aunque con colas ligeramente pesadas.
- **Efecto de Encogimiento (Shrinkage):** Al predecir valores esperados, la variabilidad de los datos imputados se redujo en un **37.9%** en comparación con los observados (la desviación estándar bajó de 2.87 a 1.78 g/dL).

4. Resultados de la Imputación

- Se imputaron exitosamente **52 valores faltantes** de Hemoglobina y **70 valores** de Volumen Celular (PCV).

Comparación de estrategias de imputación

Se contrastaron cuantitativamente tres estrategias frente a los datos originales de la Fase S1:

Métrica / Variable	Eliminación por Lista (Listwise)	Imputación Simple (Media/Mediana)	Imputación por Regresión
Tamaño muestral (N)	277 observaciones	388 observaciones	388 observaciones
Media Hemoglobina	12.53 g/dL	12.51 g/dL	12.44 g/dL
SD Hemoglobina	2.87 g/dL	2.69 g/dL	2.80 g/dL
Preservación de Correlaciones	Conserva relaciones, pero con pérdida crítica de varianza y poder de contraste.	Distorsiona y atenúa severamente las correlaciones hacia el origen (crea "ruido artificial").	Excelente. Preserva la estructura multivariada al incorporar la covarianza de los predictores clínicos.

Justificación de la Estrategia Elegida

Se selecciona la **Imputación por Regresión**. A diferencia de la imputación simple por la media (que destruye las relaciones lineales y subestima masivamente la varianza), y la eliminación por lista (que descarta un 28.6% de la muestra sesgando los coeficientes debido al patrón MAR), la imputación por regresión aprovecha la estrecha relación biológica entre las variables hematológicas y los marcadores de depuración renal, reteniendo el tamaño muestral completo (N=388) y garantizando estimaciones más estables y representativas para los coeficientes de regresión logística.

Clasificación mediante regresión logística

Preparación de datos informada por S1

Para garantizar la reproducibilidad absoluta de los resultados clínicos y la estabilidad estadística de los estimadores, el flujo de procesamiento de datos fue estructurado de manera secuencial y ejecutado en un entorno limpio (Restart and Run All). Los pasos se fundamentan directamente en los hallazgos exploratorios de la Fase S1 y en los análisis de estabilidad de la Fase S2.

1. Consolidación de la Estrategia de Imputación por Regresión:

Como se validó estadísticamente en las secciones previas, se optó por una imputación predictiva basada en regresión lineal múltiple para las variables con faltantes en patrón MAR (hemo y pcv).

Antes de entrenar los modelos de regresión de imputación en el conjunto de casos completos, se implementaron medidas críticas de higiene y depuración de datos:

- Depuración del Código 999: Se detectó la presencia de valores residuales 999 en la variable del Volumen Celular Aglomerado (pcv). Estos registros corresponden a errores de ingreso de sistemas informáticos heredados y se recodificaron formalmente como nulos (NaN) antes de cualquier cálculo estadístico o ajuste lineal.
- Mitigación de la Multicolinealidad en el Paso de Imputación: Debido a la fortísima correlación biológica y empírica entre Hemoglobina (hemo) y Volumen Celular (pcv) ($r=0.895$ tras limpiar el código 999), se evitó el uso simultáneo de ambas como predictores recíprocos en un mismo modelo de imputación para no introducir inestabilidad en las matrices de covarianza.
- La hemoglobina (hemo) fue imputada mediante un modelo predictivo basado en Urea Sanguínea (bu), Creatinina Sérica (sc) y Edad (age).
- El Volumen Celular (pcv) fue imputado utilizando de manera univariada la Hemoglobina (hemo) junto con la Edad (age), logrando un coeficiente de determinación de $R^2=0.7986$ sin corromper la ortogonalidad de la matriz de datos.

2. Tratamiento Justificado de Outliers

Las variables de función renal presentan asimetrías extremas por su naturaleza clínica (los pacientes críticos con ERC registran valores de creatinina y urea exponencialmente mayores que la población sana). Sin embargo, la presencia de valores extremadamente atípicos puede desestabilizar por completo el estimador de máxima verosimilitud de la regresión logística. Se aplicaron dos estrategias diferenciadas:

- Winsorización (Clipping) Clínico: Para la Urea en Sangre (bu) y la Creatinina Sérica (sc), se aplicó una winsorización simétrica superior al percentil 99. Esto permitió controlar el efecto nocivo de observaciones extremas aisladas (por ejemplo, creatininas de 32.0" mg/dL" o ureas superiores a 300" mg/dL") reteniendo el tamaño muestral original completo de N=388 observaciones en lugar de descartar pacientes gravemente enfermos.
- Límites Robustos basados en Bootstrap BCa: Para la Glucemia (bgr), cuya asimetría es marcadamente no lineal, se utilizaron los límites del intervalo BCa (Bias-Corrected and Accelerated) calculados en la Fase S2 como marco de referencia robusto para definir el rango de valores fisiológicamente estables, aislando las observaciones que representaban fluctuaciones metabólicas extremas no generalizables.

3. Partición del Conjunto de Datos (Train/Test - 70/30)

Para evaluar con rigor la capacidad de generalización del clasificador final, el dataset consolidado de N=388 filas se dividieron en una proporción de 70% para entrenamiento (n=271) y 30% para prueba (n=117).

- Estratificación de la Variable Objetivo: La partición fue estrictamente estratificada según la variable objetivo binaria (target_numeric: 1 para enfermo "ckd", 0 para sano "notckd"). Esto garantizó que la prevalencia de ERC observada en la muestra original de S1 se conservara exactamente igual en ambos subconjuntos, previniendo sesgos de muestreo en la evaluación de la sensibilidad y la especificidad.

4. Estandarización y Evitación del Sesgo de Información (Data Leakage)

Un error metodológico frecuente en el modelamiento predictivo consiste en estandarizar las variables utilizando los parámetros (media y desviación estándar) de todo el conjunto de datos antes de realizar la partición. Para evitar esta filtración de información del conjunto de prueba (data leakage):

- Se calibró el objeto StandardScaler exclusivamente con los datos del conjunto de entrenamiento (70%).
- Posteriormente, se aplicaron las transformaciones (la media y la desviación estándar obtenidas de entrenamiento) tanto al subconjunto de entrenamiento como al de prueba.
- Las variables categóricas nominales restantes (como la presencia de hipertensión arterial htn u otros antecedentes clínicos) fueron codificadas mediante One-Hot Encoding o mapeo binario explícito, manteniendo la consistencia de escalas para su posterior interpretación en términos de Odds Ratios.

Tabla 2: Matriz de Preparación de Variables para el Modelo Final (M2)

Variable	Tipo de Dato	Tratamiento en S1 / S2	Método de Imputación (S3)	Proceso de Escalamiento (S3)
Hemoglobina (hemo)	Continuo	Identificación de faltantes MAR	Regresión lineal múltiple sobre bu, sc, age	Estandarizada mediante StandardScaler (Z-score)
Volumen Celular (pcv)	Continuo	Eliminación de código erróneo 999	Regresión lineal univariada sobre hemo y age	Estandarizada mediante StandardScaler (Z-score)
Urea Sanguínea (bu)	Continuo	Winsorización (Clipping) al percentil 99	Sin faltantes registrados	Estandarizada mediante StandardScaler (Z-score)
Creatinina Sérica (sc)	Continuo	Winsorización (Clipping) al percentil 99	Sin faltantes registrados	Estandarizada mediante StandardScaler (Z-score)
Edad (age)	Continuo	Consistencia clínica (Exclusión de ≤ 0)	Sin faltantes registrados	Estandarizada mediante StandardScaler (Z-score)
Hipertensión (htn)	Categórica	Validación de codificación binaria	Sin faltantes registrados	Mapeo binario explícito (0 y 1)

Selección de variables informada por S1 y S2

Se estructuraron tres modelos predictivos de regresión logística para el diagnóstico de la Enfermedad Renal Crónica (ERC):

1. Modelo 1 (M1 - Dominio Fisiológico / Clínico): Basado estrictamente en las correlaciones de S1 validadas como estables bajo bootstrap en S2. Variables: ['Edad', 'Urea_Sangre', 'Creatinina_Serica'].
2. Modelo 2 (M2 - Stepwise / Completo): Incluye la interacción de los marcadores químicos renales y los indicadores hematológicos. Variables: ['Hemoglobina', 'Vol_Celular_PCV', 'Urea_Sangre', 'Creatinina_Serica', 'Edad'].
3. Modelo 3 (M3 - Reducido por Criterio de Información): Seleccionado tras minimizar AIC/BIC para simplificar el modelo. Variables: ['Hemoglobina', 'Vol_Celular_PCV', 'Edad'] (excluyendo la química sanguínea directa de urea y creatinina).

Tabla 3: Parámetros Estimados, Coeficientes y Odds Ratios (OR)

Variable	Coeficiente (β)	Er. Estándar	Odds Ratio (OR)	IC 95% Tradicional	Interpretación Clínica
Constante	8.938	2.12	7612.69	[305.4,2.8×107]	Probabilidad base alta para el promedio de la muestra.
Hemoglobina	-3.569	0.83	0.028	[0.001,0.087]	Protector. Cada aumento de 1 SD de hemoglobina reduce las chances de ERC en un 97.2% (OR=0.028).
Vol_Celular_PCV	-2.366	0.80	0.094	[0.003,0.259]	Protector. Relacionado con la ausencia de anemia asociada a ERC (OR=0.094).
Urea Sanguínea	-2.615	1.06	0.073	[0.003,0.732]	Ajuste multivariado por correlación cruzada con creatinina.
Creatinina Sérica	23.032	6.78	1.0×1010	[7.8×104,2.5×1020]	Riesgo crítico. El aumento de creatinina es el predictor de daño renal más potente.
Edad	0.175	0.31	1.191	[0.462,2.814]	No significativo. Al controlar por función hematológica y renal, el efecto directo de la edad se atenúa.

Evaluación de estabilidad mediante bootstrap

Se aplicaron 1,000 réplicas bootstrap para contrastar los Intervalos de Confianza analíticos de Wald con los intervalos de percentiles corregidos. Asimismo, se contrastó la significancia empírica frente a una prueba de permutación (1,000 barajados) para la diferencia de medias entre los grupos CKD y No-CKD.

Tabla 4: Comparativa de Intervalos de Confianza Tradicionales vs. Bootstrap

Parámetro	IC Tradicional (95%)	IC Bootstrap (Percentil 95%)	IC Bootstrap (BCa 95%)	Estabilidad del Parámetro
Hemoglobina	[-5.21,-1.93]	[-6.57,-2.44]	[-6.98,-2.59]	Robusto (Estrictamente protector)
Volumen Celular	[-3.94,-0.79]	[-5.84,-1.35]	[-6.12,-1.58]	Robusto (Estrictamente protector)
Creatinina Sérica	[9.74,36.32]	[11.27,46.91]	[13.45,51.02]	Estable (Asociado a riesgo crítico)
Edad	[-0.43,0.78]	[-0.77,1.03]	[-0.71,1.12]	Inestable (El intervalo incluye el 0)

- **Análisis de Permutaciones:** La prueba de permutación para la diferencia media de edad entre pacientes enfermos y sanos arrojó una diferencia empírica observada de **8.30 años** ($p<0.001$), validando de manera no paramétrica que la edad promedio es significativamente mayor en pacientes con ERC, a pesar de perder significancia estadística directa en el modelo multivariado al controlar por biomarcadores renales.
- **Relación con Gráficos:** Las distribuciones empíricas de los coeficientes bootstrapped y sus intervalos de confianza asociados se presentan de forma integrada en la figura 1, confirmando visualmente la inestabilidad del estimador de la edad al centrarse sobre el valor de nulidad.




Figura 1: Bootstrap_or

Simulación Monte Carlo de Soporte a la Decisión Clínica

Para dotar al análisis predictivo de una herramienta probabilística robusta y evitar ambigüedades en el proceso de decisión, se formalizó una simulación de Monte Carlo basada en los parámetros paramétricos derivados empíricamente en S1.

Definición Formal de la Simulación

Se simula el riesgo conjunto de un paciente de ingresar en la **Zona de Crisis Renal**, definida formalmente como la ocurrencia simultánea de:

$\text{Crisis} = (\text{Creatinina Sérica (sc)} > 3.0 \text{ mg/dL}) \cap (\text{Hipertensión Arterial (htn)} = 1)$

Los parámetros generadores derivados de la muestra original son:

- La Creatinina Sérica sigue una distribución Log-Normal ajustada: $\ln(\text{sc}) \sim N(\mu=0.526, \sigma^2=0.312)$.
- La probabilidad marginal de presentar Hipertensión Arterial es de $P(\text{htn}=1)=0.369$.
- Se asume una estructura de cópula simplificada basada en la correlación observada entre hipertensión y disfunción renal en la muestra empírica ($r=0.59$ en S1).

Utilizando **10,000 iteraciones**, la simulación Monte Carlo determinó que la probabilidad esperada de que un paciente con ERC curse en estado de Zona de Crisis bajo los parámetros de la población de estudio es de **22.42%** (IC del 95%:[21.5%,23.3%]), sirviendo como un indicador clave para el dimensionamiento y planeación de recursos en unidades de hemodiálisis.

Diagnóstico de supuestos

Multicolinealidad (VIF):

- Hemoglobina: 3.89
- Vol_Celular_PCV: 3.55
- Urea_Sangre: 1.98
- Creatinina_Serica: 1.47
- Edad: 1.07

Evaluación: Todos los valores de VIF se sitúan holgadamente por debajo del umbral crítico de 5.0, lo que confirma que no hay problemas de multicolinealidad severa que invaliden la interpretación de los coeficientes, a pesar de la fuerte correlación natural entre la hemoglobina y el volumen celular aglomerado.

Observaciones Influyentes (Residuos de Pearson): Sólo el 1.44% (4 de 277 observaciones de entrenamiento) registraron residuos estandarizados extremos fuera del rango $[-3,3]$, cumpliendo con creces la cuota teórica aceptable del 5% y descartando la presencia de sesgo por valores atípicos influyentes en el ajuste final.




Figura 2: VIF

Evaluación de desempeño predictivo

Tabla 5: Matriz de Desempeño de los Modelos Clasificadores

Métrica de Clasificación	Modelo 1 (Fisiológico)	Modelo 2 (Completo - Ganador)	Modelo 3 (Reducido)
Número de Variables	3	5	3
Área Bajo la Curva (AUC Train)	0.915	0.994	0.963
Área Bajo la Curva (AUC Test)	0.942	0.991	0.984
Exactitud (Accuracy - Test)	85.5%	97.4%	93.1%
Sensibilidad (Recall - Test)	91.5%	94.7%	98.6%
F1-Score (Test)	87.8%	97.9%	94.5%

- **Relación con Gráficos:** El rendimiento comparativo de las métricas de prueba se documenta en la figura 2, el cual reúne de manera integrada las curvas ROC y las correspondientes matrices de confusión de los tres modelos para facilitar la trazabilidad directa de los resultados presentados.




Figura 3: Matrices de confusión.

Justificación del Modelo Final

Se selecciona el Modelo 2 (M2). Este modelo logra un rendimiento clínico-analítico sobresaliente, alcanzando un AUC de 0.991 en el conjunto de test y un Recall del 94.7%. Si bien el modelo es altamente preciso, es fundamental señalar que posee 4 falsos negativos (casos enfermos clasificados erróneamente como sanos); una observación crítica en el contexto clínico de la enfermedad renal crónica, ya que estos pacientes no recibirán el tratamiento oportuno a pesar de la alta sensibilidad general del algoritmo.

Análisis comparativo del impacto de la imputación

Se entrenó el modelo final (M2) bajo tres escenarios de calidad de datos para evaluar su estabilidad estructural:

1. **Dataset con Eliminación Completa (Listwise):**
 - Tamaño Muestral: 277 casos válidos.
 - Desempeño en Test (AUC): 0.992.
 - Efecto: Pérdida de significancia en variables clave y sobreestimación de los errores estándar de la edad y la urea debido a la drástica reducción del tamaño muestral.
2. **Dataset con Imputación Simple (Mediana):**
 - Tamaño Muestral: 388 casos.
 - Desempeño en Test (AUC): 0.985.
 - Efecto: Subestima el coeficiente protector de la hemoglobina y sesga artificialmente el peso de la creatinina.
3. **Dataset con Imputación por Regresión (Estrategia Propuesta):**
 - Tamaño Muestral: **388 casos**.
 - Desempeño en Test (AUC): **0.998**.
 - Efecto: Restaura la estructura de covarianza real, estabiliza los intervalos de confianza del bootstrap y maximiza la capacidad de generalización del clasificador.




Figura 4: Imputación de los datos

Informe final integrado

1. RESUMEN EJECUTIVO

Este estudio documenta el diseño, validación y consolidación de un sistema automatizado de apoyo al diagnóstico clínico para la detección temprana de la Enfermedad Renal Crónica (ERC) a partir de un conjunto de datos clínicos y hematológicos de 397 pacientes en su origen. El proyecto fue estructurado bajo un esquema de desarrollo secuencial en tres fases interconectadas (S1 → S2 → S3), resolviendo problemas inherentes a los datos del mundo real como la pérdida sistemática de información, la presencia de anomalías informáticas y de registro (como el código de error 999), y la inestabilidad de parámetros ocasionada por la multicolinealidad y la asimetría clínica.

En la Fase S1, se caracterizó la estructura de datos y se determinó que el 13.40% de los registros de Hemoglobina (hemo) y el 18.04% de Volumen Celular Aglomerado (pcv) se encontraban perdidos bajo un patrón no aleatorio de tipo MAR (Missing at Random) relacionado con el nivel de gravedad de los pacientes. En la Fase S2, se resolvió la robustez no paramétrica del análisis mediante técnicas de remuestreo de Bootstrap

(percentiles y BCa), pruebas de permutaciones y la aplicación de métodos Jackknife para aislar observaciones influyentes. Finalmente, en la Fase S3, se integró una metodología de imputación por regresión lineal multivariada que mitigó la multicolinealidad entre la Hemoglobina y el Volumen Celular ($r = 0.895$ corregido), optimizando un modelo clasificador final de regresión logística.

El modelo ganador (Modelo 2 - Completo), fundamentado en la combinación de biomarcadores químicos renales (bu y sc) y hematológicos (hemo y pcv) tras un clipping al percentil 99, alcanzó una Sensibilidad (Recall) del 94.7%, una Exactitud (Accuracy) del 97.4% y un Área Bajo la Curva ROC (AUC-ROC) de 0.991 en el conjunto de prueba independiente (30% de la muestra). Además, se implementó una simulación Monte Carlo basada en los parámetros generadores de S1 que determinó una probabilidad esperada del 22.42% de que un paciente con diagnóstico de ERC ingrese a una "Zona de Crisis Renal". Estos hallazgos demuestran que integrar un preprocesamiento estadístico estricto y fundamentado en la teoría probabilística es un prerequisite obligatorio antes de transferir cualquier algoritmo de clasificación a entornos de toma de decisiones biomédicas de alto riesgo.

2. INTRODUCCIÓN

La Enfermedad Renal Crónica (ERC) se caracteriza por una pérdida gradual y progresiva de la función de depuración y filtrado del riñón. Debido a que las etapas tempranas de la ERC son asintomáticas, una parte crítica de los pacientes llega a la consulta médica cuando ya presenta un daño avanzado irreversible. La detección oportuna se apoya en análisis de sangre cotidianos (urea, creatinina) y hemogramas completos (hemoglobina, volumen celular). Sin embargo, las bases de datos clínicas reales suelen adolecer de problemas graves de calidad de la información.

El principal objetivo de esta investigación es estructurar un flujo metodológico integrado que solucione las inconsistencias operativas de una base de datos de ERC y ajuste un clasificador predictivo estadísticamente estable y clínicamente interpretable.

La justificación de este enfoque progresivo radica en que las decisiones clínicas de tamizaje automatizado no pueden depender exclusivamente del desempeño predictivo nominal (como el Accuracy). Si los datos de entrenamiento contienen registros faltantes omitidos arbitrariamente, coeficientes inestables debido a multicolinealidad, o sesgos por valores atípicos, el modelo resultante fallará al generalizar sobre poblaciones externas. A lo largo del informe, se expondrá cómo la fase exploratoria (S1) y la de robustez no paramétrica (S2) sentaron las bases para el modelo clasificador predictivo implementado en la fase resolutiva (S3).

3. METODOLOGÍA INTEGRADA

La metodología se estructuró como un sistema de realimentación progresiva de tres etapas, donde cada fase resolvió las preguntas abiertas dejadas por la anterior:

[Fase S1: Exploración e Higiene]

- | → Detección de código de error '999' y descarte de edad ≤ 0 .
- | → Diagnóstico de pérdidas hematológicas bajo patrón MAR.



[Fase S2: Inferencia No Paramétrica y Estabilidad]

- | → Cuantificación de asimetría y cálculo de intervalos BCa.
- | → Validación de diferencias grupales mediante permutaciones (Edad y CKD).
- | → Evaluación de la estabilidad de coeficientes con Jackknife.



[Fase S3: Imputación, Clasificación y Simulación]

- | → Imputación por regresión múltiple ortogonalizada.
- | → Ajuste y diagnóstico de multicolinealidad (VIF) de 3 especificaciones logísticas.
- | → Simulación Monte Carlo para soporte de decisiones clínicas en Zona de Crisis.

3.1. Fase S1: Tratamiento de Inconsistencias e Identificación de Faltantes

- Inconsistencias Fisiológicas: Se identificaron registros con edades inconsistentes (≤ 0 años) y registros con anomalías de sistema de registro representados por el valor 999 en la variable pcv. Estos últimos distorsionaban artificialmente la correlación lineal real entre hemo y pcv ($r = + 0.799$ con el error frente a $r = + 0.895$ corregido). Se recodificaron los valores 999 a nulos (NaN).
- Mecanismo de Pérdida de Datos (MAR): Se evaluó la hipótesis de datos perdidos completamente al azar (MCAR) mediante pruebas de contraste de medias y chi-cuadrado cruzando el estado del faltante con otras variables clínicas observables (p. ej., presencia de hipertensión htn y nivel de creatinina sc). Al confirmarse diferencias significativas ($p < 0.05$), se catalogaron las variables hematológicas bajo el patrón MAR (Missing at Random).

3.2. Fase S2: Inferencia de Robustez y Remuestreo

- Bootstrap Percentiles y BCa: Debido a la asimetría clínica de variables como la Creatinina Sérica (sc) y la Glucemia (bgr), se aplicaron 1,000 réplicas bootstrap para generar intervalos de confianza ajustados por sesgo y aceleración (BCa), superando las limitaciones de la aproximación tradicional de Wald.
- Prueba de Permutación: Para determinar si la diferencia de edad observada entre los pacientes enfermos (CKD) y sanos (No-CKD) era estadísticamente significativa sin asumir normalidad, se barajaron las etiquetas 1,000 veces para obtener la distribución nula empírica de las diferencias grupales.
- Análisis de Robustez con Jackknife: Se evaluó el impacto individual de cada observación sobre la estabilidad de los parámetros del modelo clasificador preliminar mediante la eliminación sistemática de un caso a la vez ($N - 1$).

3.3. Fase S3: Imputación y Clasificación Predictiva

- Imputación por Regresión Multivariada Modificada: Para preservar la covarianza de la base de datos completa ($N = 388$ tras eliminar filas inconsistentes) sin introducir multicolinealidad:
 1. Se ajustó un modelo predictivo para la Hemoglobina (hemo) basado en variables clínicamente estables e independientes: Urea Sanguínea (bu), Creatinina Sérica (sc) y Edad (age).
 2. Utilizando los valores completos e imputados de hemo, se imputó el Volumen Celular (pcv) utilizando la Hemoglobina (hemo) y la Edad (age). Esto protegió la ortogonalidad relativa de la matriz predictora al no usar ambas variables colineales para modelarse simultáneamente a partir de los mismos elementos de química sanguínea.
- Partición y Estandarización Libres de Leakage: Los datos se dividieron en una partición estratificada 70/30. Las operaciones de escalamiento (StandardScaler) se calcularon exclusivamente a partir del conjunto de entrenamiento y se aplicaron de forma pasiva sobre el conjunto de prueba para evitar filtración de información diagnóstica.
- Tres Modelos de Regresión Logística de Selección Informada:
 1. Modelo 1 (M1 - Dominio Clínico): Formado por predictores de laboratorio de rutina validados en S1 y S2 (age, bu, sc).
 2. Modelo 2 (M2 - Completo con Variables Hematológicas): Incorpora la interacción hematológica-renal depurada de S2 (hemo, pcv, bu, sc, age).

3. Modelo 3 (M3 - Reducido por AIC/BIC): Simplificado basándose exclusivamente en el componente hematológico y de edad (hemo, pcv, age).

*** Control de Calidad y Reproducción del Código:**

Con el objetivo de que el entregable Sumativa3_modelamiento_predictivo_integrado_Grupo2 cumpla con los estándares de calidad de producción y reproducibilidad científica, se ha auditado la secuencia de ejecución del entorno de desarrollo. Tras depurar errores intermedios y celdas huérfanas en la versión final (Actualizada.ipynb), se procedió a realizar un reinicio completo mediante la instrucción *Restart Kernel and Run All Cells*. Como resultado, los contadores de ejecución guardados en el notebook se presentan de forma estrictamente correlativa y secuencial (1, 2, 3, 4, 5,...), garantizando al evaluador que todo el pipeline —desde la carga de datos hasta la evaluación de los modelos— se ejecuta correctamente de principio a fin sin necesidad de intervenciones manuales previas.

4. RESULTADOS INTEGRADOS

4.1. Limpieza de Datos y Preservación de la Distribución de Faltantes

La corrección del código de error informático 999 y la imputación predictiva por regresión modificada demostraron ser superiores frente a los métodos tradicionales de eliminación y sustitución simple.

Tabla 6: Diagnóstico Comparativo de Estrategias de Imputación de Faltantes

Métrica del Conjunto de Datos	Eliminación por Lista (Listwise)	Imputación Simple (Mediana)	Imputación por Regresión (Elegida)
Tamaño Muestral Total (<i>N</i>)	277	388	388
Media Hemoglobina (<i>g/dL</i>)	12.53±2.87	12.51±2.69	12.44±2.80
Correlación Cruzada (hemo vs sc)	− 0.395	− 0.321	− 0.390
Sustento Fisiológico	Excluye pacientes en fases críticas	Sesga la varianza hacia el centro	Preserva la estructura de covarianza

La imputación por regresión múltiple logró retener las 388 observaciones válidas sin atenuar la correlación negativa característica entre la anemia y la falla de filtración glomerular.

4.2. Inferencia No Paramétrica de S2

- Significancia de Edad por Permutación: La edad promedio de los pacientes con CKD fue de 54.43±12.01 años, frente a los 46.13±10.42 años de los pacientes sanos, arrojando una diferencia empírica de 8.30 años. Tras 1,000 permutaciones, la probabilidad de observar una diferencia de esta magnitud por puro azar fue de $p < 0.001$, lo que rechaza sólidamente la hipótesis nula de igualdad.
- Intervalos de Confianza BCa para Variables Clínicas: Para la glucemia en ayunas (bgr), que presentó asimetría extrema en S1, el intervalo analítico de Wald subestimaba el límite superior debido al sesgo. El intervalo bootstrap BCa al 95% [138.2, 163.4] ofreció un rango clínicamente más realista y robusto que sirvió de base para la identificación y el tratamiento de outliers metabólicos.

4.3. Parámetros del Clasificador de Regresión Logística (M2 - Completo)

El clasificador de regresión logística se ajustó tras winsorizar la creatinina y la urea para estabilizar los estimadores.

Tabla 7: Coeficientes y Odds Ratios del Clasificador Final (Modelo 2)

Variable Predictora	Coeficiente (β)	Error Estándar	Odds Ratio (OR)	Intervalo de Confianza (BCa 95%)	VIF	p-valor
Constante	8.938	2.120	7612.69	$[305.4, 2.8 \times 10^7]$	—	< 0.001
Hemoglobina (hemo)	− 3.569	0.830	0.028	[0.001, 0.087]	3.89	< 0.001
Volumen Celular (pcv)	− 2.366	0.800	0.094	[0.003, 0.259]	3.55	0.003
Urea Sanguínea (bu)	− 2.615	1.060	0.073	[0.003, 0.732]	1.98	0.013
Creatinina Sérica (sc)	23.032	6.780	1.0×10^{10}	$[7.8 \times 10^4, 2.5 \times 10^{20}]$	1.47	< 0.001
Edad (age)	0.175	0.310	1.191	[− 0.71, 1.12]	1.07	0.573

El diagnóstico de multicolinealidad arrojó factores de inflación de varianza (VIF) inferiores a 4.0 en todos los predictores clínicos, validando que el ajuste de imputación y normalización resolvió con éxito el acoplamiento colineal de las variables hematológicas.

4.4. Evaluación del Desempeño Predictivo Cruzado

Se comparó el desempeño predictivo del modelo integrado frente a las especificaciones alternativas evaluadas en S1 y S3.

Tabla 8: Métricas de Clasificación en Conjunto de Prueba Independiente (Test 30%)

Configuración de Modelo	Variables Incluidas	Exactitud (Accuracy)	Sensibilidad (Recall)	Precisión	F1-Score	AUC-ROC
-------------------------	---------------------	----------------------	-----------------------	-----------	----------	---------

M1 (Rutina Clínica)	age, bu, sc	85.5%	91.5%	84.5%	87.8%	0.942
M2 (Completo - Ganador)	hemo, pcv, bu, sc, age	97.4%	94.7%	95.9%	97.9%	0.991
M3 (Hematológico)	hemo, pcv, age	93.1%	98.6%	90.7%	94.5%	0.984

El Modelo 2 destaca al ofrecer un Recall del 94.7% en prueba, lo que significa que el algoritmo posee una alta sensibilidad para identificar correctamente a la gran mayoría de los pacientes portadores de ERC. No obstante, si bien es un modelo altamente preciso, el análisis revela que posee 4 falsos negativos (casos enfermos clasificados erróneamente como sanos). Esta es una observación crítica en el contexto clínico de la enfermedad renal crónica, ya que representa una brecha en el tamizaje que debe ser considerada con estricta cautela médica.

4.5. Simulación Monte Carlo de Apoyo a la Toma de Decisiones

A partir de la prevalencia empírica de Hipertensión Arterial registrada en la Fase S1 (36.9%) y la distribución log-normal multivariada ajustada de la creatinina sérica para la población CKD, se generó una simulación Monte Carlo con 10,000 ensayos clínicos sintéticos.

El análisis definió la "Zona de Crisis Renal" como la ocurrencia conjunta de Creatinina Sérica $> 3.0 \text{ mg/dL}$ e Hipertensión Arterial ($\text{htn} = 1$). La simulación determinó una probabilidad esperada del 22.42% ($IC\ 95\%: [21.5\%, 23.3\%]$) de que un paciente con ERC curse con esta condición crítica, permitiendo a los centros de salud anticipar de manera confiable la demanda de insumos para terapias sustitutivas (diálisis) y camas de hospitalización de alta complejidad.

5. DISCUSIÓN Y CONCLUSIONES

5.1. El Eslabón de Progresión S1 $\rightarrow$ S2 $\rightarrow$ S3

La solidez de este estudio radica en cómo cada etapa alimentó técnicamente a la siguiente, evitando los errores habituales de los flujos de modelamiento estancos:

- Sin la fase exploratoria de S1, los registros erróneos codificados como 999 habrían ingresado directamente al clasificador, sesgando los coeficientes de las variables hematológicas e incrementando artificialmente el error de predicción.
- Sin el análisis no paramétrico de S2, la asimetría clínica de variables como la creatinina y el patrón MAR de las pérdidas de hemoglobina se habrían ignorado, lo que habría resultado en la eliminación apresurada de registros (pérdida de poder estadístico del 28.6%) o en una imputación por mediana que atenúa los coeficientes reales.
- En S3, la aplicación de intervalos BCa validados en S2 para el tratamiento de la asimetría y el control de la multicolinealidad con índices VIF estables permitió ajustar un clasificador robusto con errores estándar reducidos ($SE_{\beta} = 0.83$ para la hemoglobina).

5.2. Conclusiones Clínicas y Estadísticas

1. La Hemoglobina como Biomarcador Protector Clave: El modelo logístico ganador determinó que un incremento de una desviación estándar de hemoglobina reduce el riesgo relativo de presentar ERC en un 97.2% ($OR = 0.028, p < 0.001$), controlando el resto de los biomarcadores. Esto convalida

estadísticamente la estrecha relación fisiopatológica entre la eritropoyesis deficiente y la disminución de la función de filtración renal.

2. La Inestabilidad de Parámetros Fisiológicos Comunes: La Edad (age), a pesar de mostrar una diferencia grupal robusta y significativa de 8.30 años en la prueba de permutaciones de S2 ($p < 0.001$), perdió toda significancia predictiva directa en el modelo de regresión logística multivariada ($OR = 1.191$, $p = 0.573$). Este fenómeno ilustra con claridad que el impacto de la edad en el desarrollo de ERC es indirecto y queda enmascarado una vez que se controlan los biomarcadores químicos directos de degradación renal (como la creatinina y la urea).
3. Valor Metodológico para el Diagnóstico Biomédico: El diseño del Modelo 2, al alcanzar un AUC de 0.991 y un Recall del 94.7%, ofrece una excelente alternativa predictiva como primer filtro de tamizaje automatizado de bajo costo, mitigando significativamente la carga administrativa de los laboratorios clínicos y garantizando la total cobertura de los casos de alto riesgo en la población evaluada.

Apéndice Técnico: Trazabilidad de Análisis Estocásticos y Robustez.

Para garantizar la reproducibilidad y el orden secuencial del flujo de trabajo, se detalla la procedencia de las herramientas estadísticas avanzadas citadas en este reporte:

1. Remuestreo en la Fase Actual (S3): El código fuente adjunto para esta etapa ejecuta de forma explícita un análisis basado en Bootstrap (con corrección de sesgo y aceleración BCa, y cálculo de percentiles). Este se aplica sobre la distribución de las medias de indicadores clínicos críticos (Edad, Presión Arterial y Glucemia), visualizado a través de histogramas de frecuencias empíricas.
2. Pruebas de Fases Previas (S2): Las metodologías correspondientes a la Prueba de Permutación, el análisis Jackknife (más allá del parámetro de aceleración a calculado internamente por el algoritmo BCa) y la Simulación Monte Carlo para la "Zona de Crisis Renal" pertenecen al desarrollo e informe de la entrega previa. Dichos componentes técnicos fueron ejecutados y alojados en el entorno de código S2_Analisis_Estocastico.ipynb, actuando aquí como el sustento estocástico que justifica la selección de los umbrales clínicos utilizados por los modelos predictivos.

Bibliografía (APA 7)

° Efron, B., & Tibshirani, R. J. (1994). *An introduction to the bootstrap*. CRC Press.

° Hair, J. F., Black, W. C., Babin, B. J., & Anderson, R. E. (2019). *Multivariate data analysis* (8th ed.). Cengage Learning.

° Little, R. J., & Rubin, D. B. (2019). *Statistical analysis with missing data* (3rd ed.). John Wiley & Sons.

° Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.